

Kaggle LLM Science Exam: Çoktan Seçmeli Akademik Soru Çözüm Sistemleri İçin QLoRA Tabanlı Büyük Dil Modeli (LLM) İnce Ayar Teknik Raporu

Yazar: Serdar Önal

Rol: Kıdemli Veri Bilimci / Yapay Zeka Araştırmacısı

Tarih: 16 Mayıs 2026

Model Altyapısı: Qwen2.5-1.5B-Instruct & DeBERTa-v3 Baseline

1. GİRİŞ VE PROBLEM TANIMI

Bu çalışma, yüksek düzeyde akademik ve teknik uzmanlık gerektiren (Fizik, Kimya, Biyoloji, Bilgisayar Bilimleri, Astronomi vb.) çoktan seçmeli bilimsel soruların, Yapay Zeka modelleri tarafından insan seviyesinde çözülmesini hedeflemektedir.

Yarışma veri seti (`train.csv`), sınırlı sayıda (200 satır) ancak yoğun bilgi içeren sorulardan oluşmaktadır. Projenin temel mühendislik zorluğu, bu dar veri kümesi üzerinde aşırı öğrenmeyi (overfitting) engelleyerek, modelin akademik muhakeme (reasoning) yeteneğini maksimize etmektir.

2. SİSTEM MİMARİSİ VE METODOLOJİ

Proje kapsamında iki farklı jenerasyon model mimarisi test edilmiş ve evrilmiştir:

2.1. Başarısız Denemeler: Klasik Encoder Sınırları (DeBERTa Baseline)

İlk fazda, Kaggle NLP yarışmalarının geleneksel favorisi olan `microsoft/deberta-v3-base` mimarisi üzerinde çoklu seçim (Multiple Choice) kafası eklenerek klasik fine-tuning denenmiştir. Ancak, modelin parametre hacminin darlığı ve harici bir bilgi bankası (RAG) olmadan doğrudan eğitilmesi, modelin **%20.00 (rastgele sallama olasılığı)** barajını aşamamasına neden olmuştur.

2.2. Başarılı Strateji: Causal LM & QLoRA Entegrasyonu (Qwen2.5)

İkinci fazda sistem, üretken yapay zeka (Generative AI) paradigmalarına kaydırılmıştır. Qwen2.5-1.5B-Instruct modeli mimarinin merkezine oturtulmuştur.

A. 4-Bit Kuantizasyon (NF4)

Model, bellek verimliliğini optimize etmek ve Kaggle T4 GPU sınırlarında (16GB VRAM) donanım hatası (OOM) almamak adına `BitsAndBytesConfig` ile **NF4 (NormalFloat4)** veri tipinde simüle edilmiştir. Hesaplama dtypesi olarak `torch.float16` seçilerek işlem hızı maksimize edilmiştir.

B. Parametre Verimli İnce Ayar (PEFT / QLoRA)

Milyarlarca parametreye sahip ana modelin tüm ağırlıklarını eğitmek yerine, sadece dikkat (attention) katmanlarına düşük dereceli adaptörler (LoRA) eklenmiştir.

- **LoRA Rank (\$r\$):** 32
- **LoRA Alpha (\$\alpha\$):** 64
- **Hedef Modüller:** `q_proj`, `k_proj`, `v_proj`, `o_proj`
- **Trainable Parameter Oranı:** Toplam parametrelerin yaklaşık %1.5'i.

C. Bütünsel Prompt Mühendisliği (Choice-Merged Format)

Her şıkkı modele ayrı ayrı tokenize ederek verip olasılık hesaplatmak yerine, modern LLM yeteneklerinden faydalanılarak soru ve tüm şıklar tek bir bağlamda birleştirilmiştir:

Plaintext

Answer the following multiple choice question.

Question: [Soru Metni]

Choices:

A. [Seçenek A]

B. [Seçenek B]

...

Answer: [Hedef Etiket]

3. DENEYSEL SONUÇLAR VE METRİKLER

Model, stratified %10 split ile ayrılan doğrulama kümesinde (Validation Set) 2 epoch boyunca eğitilmiş ve test edilmiştir.

3.1. Eğitim Karakteristiği (Loss Yakınsaması)

- **Training Loss (1. Epoch sonunda):** 0.9124
- **Validation Loss (1. Epoch sonunda):** 1.0829

Kayıp (Loss) değerinin kararlı bir şekilde 1.0 seviyelerine inmesi, Qwen modelinin çoktan seçmeli soru yapısını ve doğru şık arasındaki semantik ilişkiyi başarılı bir şekilde öğrendiğini doğrulamaktadır.

3.2. Sınıflandırma Performansı (Classification Report)

Modelin genel lokal doğruluk oranı **%80.00 Accuracy** olarak tescillenmiştir.

Plaintext

	precision	recall	f1-score	support
A	0.80	1.00	0.89	4
B	0.80	0.80	0.80	5
C	0.75	0.75	0.75	4
D	0.80	1.00	0.89	4
E	1.00	0.33	0.50	3
accuracy			0.80	20
macro avg	0.83	0.78	0.77	20
weighted avg	0.82	0.80	0.78	20

4. DERİNLEMESİNE HATA ANALİZİ (ERROR AUDIT)

Sınıflandırma raporu ve tahmin çıktıları kalitatif ve kantitatif olarak incelendiğinde şu sonuçlar elde edilmiştir:

- A ve D Şıklarında Mutlak Başarı (Recall: 1.00):** Model, doğru cevabı A ve D olan hedef sınıfların hiçbirini ıskalamamış, %100 hassasiyetle yakalamıştır.
- E Şıkkı Sıkışması ve Muhafazakar Karar Mekanizması:** E şıkkının **Precision** değeri 1.00 çıkmıştır. Yani model bir soruya "E" yanıtını verdiğinde yanılmamıştır. Ancak **Recall** değeri 0.33'te kalmıştır.
 - Kök Sebebin Analizi:** Doğru cevabı E olan bazı üst düzey, çok uzun ve karmaşık akademik terminoloji içeren sorularda model risk almaktan kaçınmıştır. Modelin "Inference" aşamasında **max_new_tokens=1** olarak sınırlandırılması ve olasılık dağılımında (Logits) E şıkkının kelime sınırında kalması, modelin daha baskın ve güvenli gördüğü A veya D şıklarına yönelmesine (bias) yol açmıştır.

Canlı Başarı Örnekleri

- Mekanik Muhakeme Testi (Başarılı):** Vida ve somunların sıkılması/gevşetilmesi esnasında "Sağ El Kuralı" (**right-hand rule**) kullanımına dair gelen mühendislik sorusuna model **B şıkkı** diyerek doğru yanıt vermiştir.
- Kozmoloji Testi (Başarılı):** Evrenin genişleme geçmişini belirlemede kırmızıya kayma-mesafe ilişkisinin (**redshift-distance relationship**) önemini sorgulayan karmaşık fizik sorusunu **E şıkkı** ile kusursuz tahmin etmiştir.

5. GELECEK ÇALIŞMALAR VE SİSTEM GELİŞTİRME ÖNERİLERİ (PLAN B & C)

Sistemin %80.00 olan başarı oranını %90.00 ve üzerine taşımak için bir sonraki fazda uygulanması önerilen mimari stratejiler şunlardır:

- Position Augmentation (Şık Rotasyonu):** Sorulardaki şıkların yerleri değiştirilerek (A şikkını E'ye, E'yi B'ye taşıyarak) veri seti 5 katına çıkarılmalıdır. Bu sayede modelin şık konumlarına olan bağımlılığı (positional bias) kırılacaktır.
- Dense Retrieval (Hibrit RAG):** BAAI/bge-small-en-v1.5 gibi bir embedding modeli kullanılarak, Wikipedia bilimsel makalelerinden soru köküne uygun paragraflar cımbızla çekilmeli ve promptun başına `Context:` olarak eklenmelidir.
- Logit Ensembling:** Qwen2.5-1.5B modelinden alınan tahmin olasılıkları (logits) ile DeBERTa-v3-large modelinin olasılıkları ağırlıklı ortalama ($0.7 * \text{Qwen} + 0.3 * \text{DeBERTa}$) ile birleştirilerek nihai oylama (Ensemble) yapılmalıdır.

6. PROJE ÇIKTILARI VE DOĞRULAMA

Proje sonunda, Kaggle çalışma dizininde resmi yarışma teslim formatına tam uyumlu `submission.csv` dosyası ve gelecekteki transfer öğrenme süreçlerinde kullanılmak üzere eğitilmiş LoRA adaptör katmanlarını içeren `llm_science_model/` ağırlık klasörü hatasız olarak üretilmiş, doğrulanmıştır.